郑策

个人信息

职位：助理研究员 (中级职称)
工作单位: 鹏城实验室
研究方向: 投机采样，KV 缓存，LLM 分布式推理，AI Infra & AI-RAN
Email: zhengc@pcl.ac.cn
chriszhengce123@163.com
手机号: +86 13335281561
+33 (0)6 19 02 31 59
个人主页: https://chriszhengce.github.io/index.html
出生地: 山东，中国
出生日期: 1991 年 10 月 15 日

工作经历

鹏城实验室 2024.09 - 至今
助理研究员（中级职称）

巴黎理工—巴黎高等电信学院 2023.07 - 2024.09
博士后

索尼中国研究院 2021.08 - 2023.06
无线研究员/研究科学家（科学家岗）
索尼 3GPP SA2 代表（Delegate）

法国科学研究院（CNRS） 2017.10 - 2020.10
研究员

教育背景

里尔大学，法国，博士 2017.10 - 2020.10
导师:
Laurent CLAVIER（法国里尔大学，法国科学院终身教授），
Malcolm EGAN（法国国家信息与自动化研究所 INRIA 终身研究员），
Jean-Marie GORCE（法国里昂国立应用科学院终身教授，法国国家信息与自动化研究所 INRIA Lyon 科学负责人，曾担任过多项法国和欧洲资助的无线通信与网络相关项目的首席研究员）

奥尔堡大学，丹麦，项目交换 2019.09 - 2019.12
导师:
Troels PEDERSEN（丹麦奥尔堡大学副教授）
Petar POPOVSKI（丹麦奥尔堡大学教授，**IEEE Fellow**，**JSAC Editor-in-Chief**，**chair of IEEE Communication Theory Technical Committee**）

西安交通大学，中国，硕士 2013.09 - 2016.07
导师：罗新民（教授，西安交通大学电信学院副院长）

哈尔滨工业大学，中国，本科 2009.09 - 2013.07

访学经历

CITI-LAB, INSA Lyon，里昂，法国 2018.12
1st Winter School on Information Theory and Signal Processing for Internet of Things

德岛大学，德岛，日本 2014.07 - 2014.08
The Electrical and Information Science Course Program

加州大学洛杉矶分校，洛杉矶，美国 2014.02 - 2014.03
American Language Center Intensive English Communication Program

奖励荣誉

鹏城特聘 C 类人才 (原孔雀计划)，深圳 2025
RMB 240,000/年，持续三年资助

Mobility Grant，欧盟 2019
支持本人在丹麦奥尔堡大学访问的费用

IRACON 5th TS Grant，欧盟 2019
支持本人在 INSA Lyon 访问的费用

研究生奖学金, 中国 2016-2019
免除三年学费及生活费支持

科研项目

鹏城算力网 3.1 2025
课题骨干: 大模型分布式部署与推理，投机采样与 KV 缓存复用共享。

索尼清华合作研究项目 (45 万人民币) 2023
项目负责人: 指导 4 名清华大学博士生，产出 3GPP 标准专利。

索尼清华合作研究项目 (60 万人民币) 2022
项目负责人: 指导 6 名清华大学博士生，产出 3GPP 标准专利。

索尼清华合作研究项目 (60 万人民币) 2021
项目负责人: 指导 6 名清华大学博士生，产出 3GPP 标准专利。

欧盟 SEAWave & GOLIAT 2023
博士后研究员参与：监测射频电磁场（Rdiao Frequency-Electromagnetic Field）的暴露情况，特别是来自 5G 网络信号的暴露，对其潜在的健康影响提供新的研究
SEAWave项目由欧盟 **Horizon Europe** 及瑞士 SERI 资助;
GOLIAT项目由 **Horizon Europe research and Innovation program** 资助。

索尼-泰山医养中心合作项目 2023
负责人: ：与泰山医养中心建立合作，与医护人员共同研究无线感知技术在重要生命体征（如心跳和呼吸）、老年人跌倒检测以及无设备活动识别等方面的应用。

法国科研署 ARBurst
博士研究员参与: 该项目由法国科研署资助，完成本人博士课题 "**Impact of impulsive and dependent interference on radio communications**"。

编程及语言技能

编程技能：Matlab, Python, Latex, Pytorch

研究技能：投机采样, KV 缓存, LLM, Copula, α-stable, 联邦学习, 3GPP SA1 & SA2

语言技能：普通话（母语）；英语（精通）；法语（初级）；日语（初级）

面向每个人的生成式 AI （Generative AI for Everyone） on Coursera 01/2024

学术论文

学术论文 28 篇，其中会议论文 15 篇，期刊论文 13 篇。Google Scholar 引用：204

期刊论文

[J13]. **Ce Zheng**, Xinghan Wang, Ning Huang, Tingting Yang, "Accelerating Edge-Device Inference: Dual-Pipeline Speculative Decoding with Hidden State Transmission and Proactive Drafting". *IEEE Internet of Things Journal*. (To be submitted)

[J12]. **Ce Zheng**, Xinghan Wang, Ning Huang, Tingting Yang, "Accelerating Federated LLM Inference via Compressed Transmission and Speculative Decoding". *IEEE Transaction on Information Theory*. (To be submitted)

[J11]. Wei Wang, Chuanting Zhang, Daojun Liang, Basem Shihada, **Ce Zheng**, Jingxuan Wei, Feng Li, Yinglong Wang. "CellularMoE: Topology-Aware Sparse LLM Adaptation for Wireless Traffic Forecasting", *IEEE Transaction on Mobile Computing* (2026). (Submitted)

[J10]. Seunghun Lee, Jihong Park, **Ce Zheng**, Hyuncheol Park. "Compressed KV Cache Migration for Low-Latency Edge LLM Handover", *IEEE Transaction on Mobile Computing* (2026). (Submitted)

[J9]. Seunghun Lee, Jihong Park, **Ce Zheng**, Hyuncheol Park. "Low-Latency Edge LLM Handover via Joint KV Cache Transfer and Token Prefill", *IEEE Transaction on Vehicular Technology* (2026).

[J8]. **Ce Zheng**, Ke Zhang, Sun Chen, Wenqi Zhang, Qiong Liu, Angesom Ataklity Tesfay. "Fast Collaborative Inference via Distributed Speculative Decoding", *Journal of Information and Intelligence (2026)*.

[J7]. Jiahong Ning, Tingting Yang, **Ce Zheng**, Xinghan Wang, Ping Feng, Xiufeng Zhang. "DeAOff: Dependence-Aware Offloading of Decoder-Based Generative Models for Edge Computing", *China Communication, 2025*.

[J6]. Hongliang He, Xingmei Li, and **Ce Zheng**. "Secure Transmission Via Constellation Splitting", *IEEE Communications Letters (2025)*.

[J5]. Jie Zhou, Shuaishuai Guo, Jia Ye, Peng Zhang, and **Ce Zheng**. "Maximal Coding Rate Reduction: A Unified Approach for Task-Oriented RIS and Communication", *IEEE Transactions on Vehicular Technology (2024)*.

[J4]. Yarui Zhang, Shanshan Wang, Wassim Ben Chikha, Jiang Liu, **Ce Zheng**, Theodoros Samaras, and Joe Wiart. "Statistical Analysis of RF-EMF Exposure Induced by Cellular Wireless Networks in Public Transportation Facilities of the Paris Region", *IEEE Access (2024)*.

[J3]. **Ce Zheng**, Malcolm Egan, Laurent Clavier, Gareth W. Peters, Jean-Marie Gorce, "On the interference arising from random spatial fields of interferers utilizing multiple subcarriers", *In EURASIP Journal on Wireless Communications and Networking. 2022 ; Vol. 2022*.

[J2]. **Ce Zheng**, Malcolm Egan, Laurent Clavier, Petar Popovski, Anders Ellersgaard Kalør, "Stochastic Resource Optimization of Random Access for Transmitters with Correlated Activation", *In 2021 IEEE Communication Letters*.

[J1]. Egan Malcolm, Laurent Clavier, **Ce Zheng**, Mauro De Freitas, Jean-Marie Gorce. "Dynamic interference for uplink SCMA in large-scale wireless networks without coordination", *EURASIP Journal on Wireless Communications and Networking* 2018, no. 1 (2018): 213.

会议论文

[C15]. **Ce Zheng**, Xinghan Wang, Jiahong Ning, Yuxuan Shi, Ning Huang, Tingting Yang. "SpecFed: Accelerating Federated LLM Inference with Speculative Decoding and Compressed Transmission". *In IEEE ISIT Workshop on Information Theory for Large Language Models (IT4LLM)*, 2026.

[C14] **Ce Zheng**, Shiyao Ma, Ke Zhang, Chen Sun, Wenqi Zhang. "Clustering-Based User Selection in Federated Learning: Metadata Exploitation for 3GPP Networks", *In IEEE Wireless Communications and Networking Conference (WCNC)*, April. 13-16, 2026.

[C13]. **Ce Zheng**, Tingting Yang. "Communication-Efficient Collaborative LLM Inference via Distributed Speculative Decoding", In *IEEE Seventeenth International Conference on Wireless Communications and Signal Processing*, Oct. 23-25, 2025.

[C12]. Jing Liang, Yuxuan Wang, Tingting Song; **Ce Zheng**, Peiya Li, "Privacy-Preserving Image Retrieval Scheme Using Combined Features in Cloud Computing", In 2025 *Asia Pacific Signal and Information Processing Association Annual Summit and Conference (APSIPA ASC)*, Singapore, Oct.22-24 2025.

[C11]. Jiahong Ning, **Ce Zheng**, Tingting Yang. "DSSD:Efficient Edge-Device LLM Deployment and Collaborative Inference via Distributed Split Speculative Decoding", *In ICML 2025 workshop on Machine Learning for Wireless Communication and Networks*.

[C10]. Jiahong Ning, Pengyan Zhu, **Ce Zheng**, Gary Lee, Sumei Sun, and Tingting Yang. "EdgePrompt: A Distributed Key-Value Inference Framework for LLMs in 6G Networks", *In INFOCOM Workshop on Pervasive Network Intelligence for 6G Networks* (2025).

[C9]. Chen Sun, Shiyao Ma, **Ce Zheng**, Songtao Wu, Tao Cui, Wenqi Zhang. "Federated Learning with CSMA based User Selection for IoT Applications", In *ICC 2024 - IEEE International Conference on Communications (ICC),* Denver, US, 2024.

[C8]. Yunda Li, Le Zhao, Chen Sun, Haojin Li, **Ce Zheng**, "An Iterative Joint Tx-Rx Hybrid Beamforming Method for Vehicular Networks", In 2023 IEEE 98th Vehicular Technology Conference (VTC2023-Fall), 1-6.

[C7]. Qiong Liu, Chenhao Wang, **Ce Zheng**, "Distributed Decisions on Optimal Load Balancing in Loss Networks", *In 21st International Symposium on Modeling and Optimization in Mobile, Ad Hoc, and Wireless Networks (WiOpt)*, Singapore, Singapore, 2023, pp. 464-471.

[C6]. Tianming Zang, **Ce Zheng (通信作者)**, Wei Chen, Shiyao Ma, Chen Sun, "A General Solution for Straggler Effect and Unreliable Communication in Federated Learning", *In ICC 2023 - IEEE International Conference on Communications (ICC),* Rome, Italy, 2023, pp. 1194-1199.

[C5]. Ce Zheng, Malcolm Egan, Laurent Clavier, Petar Popovski, Anders Ellersgaard Kalør, "Stochastic Resource Allocation for Outage Minimization in Random Access with Correlated Activation", *In 2022 IEEE Wireless Communications and Networking Conference (WCNC).* (pp. 1-6), Austin, US.

[C4]. Ce Zheng, Malcolm Egan, Laurent Clavier, Troels Pedersen and Jean-Marie Gorce. "Linear Combining in Dependent α-Stable Interference", *In 2020 IEEE International Conference on Communications (ICC)* (pp. 1-6), Dublin, Ireland.

[C3]. Ce Zheng, Egan Malcolm, Laurent Clavier, Gareth W. Peters, Gorce, Jean-Marie. "On the Validity of Isotropic Complex α-Stable Interference Models for Interference in the IoT" *In 2019 GRETSI, Groupe d'Etudes du Traitement du Signal et des Images.*

[C2]. Ce Zheng, Egan Malcolm, Laurent Clavier, Gareth W. Peters, Gorce, Jean-Marie. "Copula-Based Interference Models for IoT Wireless Networks" *In 2019 IEEE International Conference on Communications (ICC)* (pp. 1-6), Shanghai, China.

[C1]. Ce Zheng, Jiancun Fan, and Xinmin Luo. "Spectrum and energy efficiency analysis of ultra dense network with sleep." *2016 8th IEEE International Conference on Communication Software and Networks (ICCSN*).

标准化 & 项目经历

发表个人专利 14 篇，其中第一发明人 7 篇，11 篇专利已申请 PCT 国际专利。
参与中国标准化协会报告撰写一项，3GPP 标准化提案两项。
负责索尼工业项目三项，参与欧盟项目一项，法国项目一项。

专利

[P14]. 郑策, 王星翰, 宁嘉鸿, 杨勇, 黄宁, 杨婷婷. "基于投机采样的大模型分布式推理加速方法及装置".
中国专利公开号：CN120373477A
中国专利申请号：CN202510885627.8

[P13]. 郑策, 孙晨. "分层树状联邦学习网络中的节点选择和/或通信资源分配".
中国专利公开号：CN118945862A
中国专利申请号：CN202310513237.9
PCT 国际专利申请号：PCT/CN2024/091318

[P12]. 郑策, 孙晨. "用于无线通信系统的电子设备、方法和存储介质 (联邦学习中，基于 sidelink 增强的性能提升方案及用户选择机制)".
中国专利公开号：CN118828625A
中国专利申请号：CN202310436139.X
PCT 国际专利申请号：PCT/CN2024/087946

[P11]. 郑策, 孙晨. "用于无线通信的电子设备和方法、计算机可读存储介质 (分割学习辅助的联邦学习网络)".
中国专利公开号：CN118734897A
中国专利申请号：CN202310342408.6
PCT 国际专利申请号：PCT/CN2024/083483

[P10]. 郑策, 孙晨. "用于分割学习的电子设备和方法、计算机可读存储介质 (分割学习下，sidelink 增强的用户选择、用户执行顺序选择和模型传输链路选择方案)".
中国专利公开号：CN118473556A

中国专利申请号：CN202310116586.7
PCT 国际专利申请号：PCT/CN2023/099329

[P9]. **郑策**, 孙晨. “用于无线通信的电子设备和方法、计算机可读存储介质 (联邦学习下的服务保障机制)”
中国专利公开号：CN117917907A
中国专利申请号：CN202211286543.5
PCT 国际公开号：WO2024/083034 20250410
PCT 国际专利申请号：PCT/CN2023/124431 20231013

[P8]. **郑策**, 孙晨. “分层联邦学习网络中的切换”.
中国专利公开号：CN117560722A
中国专利申请号：CN202210936728.X
PCT 国际公开号：WO2024/027676 20250126
PCT 国际专利申请号：PCT/CN2023/110473 20230801

[P7]. 孙晨，**郑策**，王晓雪, 崔焘, “用于机器学习的设备、方法和系统 (事件驱动的联邦学习机制)”.
中国专利公开号：CN119106747A
中国专利申请号：CN202310684768.4
PCT 国际专利申请号：PCT/CN2024/097176

[P6]. 陈巍，刘远瑞，**郑策**，孙晨. “用于模型推理的电子设备、方法和存储介质（D2D 辅助下的用户与网络间的模型分割）”.
中国专利公开号：CN118102475A
中国专利申请号：CN202211502760.3
PCT 国际专利公开号：WO2024/114520 20250521
PCT 国际专利申请号：PCT/CN2023/133909

[P5]. 陈巍，吴俊杰，**郑策**，王晓雪，孙晨. “用于无线通信的电子设备和方法、计算机可读存储介质 (联邦学习的 V2X 边缘链路性能提升方案)”.
中国专利公开号：CN117454952A
中国专利申请号：CN202210809772.4
PCT 国际专利公开号：WO2023/226882 20241119
PCT 国际专利申请号：PCT/CN2023/095209 20230519

[P4]. 陈巍，谢瞻远，**郑策**，王晓雪，孙晨. “用于无线通信的电子设备和方法、计算机可读存储介质 (基于中继传输节点的车辆位置信息传输方法及系统)”.
中国专利公开号：CN117177209A
中国专利申请号：CN202210582464.2
PCT 国际专利公开号：WO2024/012319 20250102
PCT 国际专利申请号：PCT/CN2023/105811 20230705

[P3]. 孙晨，樊婷婷，**郑策**，“用于无线通信的电子设备和方法、计算机可读存储介质（元宇宙和 XR 大规模接入的低延迟实现）”.
中国专利申请号：202311166112.X

[P2]. 张兆宇，王晓雪，孙晨，**郑策**，“用于无线通信系统的电子设备、方法和存储介质（一种无线通信系统中的 AI 模型选择方法）”.
中国专利公开号: CN120090758A
中国专利申请号：202311644098.X

[P1]. 陈巍; 李长坤; 仇亦禹; 孙晨; 樊婷婷; **郑策**, “用于无线通信的电子设备和方法、计算机可读存储介质”.
中国专利公开号：CN119603742A
中国专利申请号：CN202311166112.X

标准化经验

中国通信标准化协会 (CCSA) 白皮书《面向原生智能的新一代无线通信与网络架构研究》
— 主要负责“6.2.1 节：无线接入网分布式学习框架介绍”的撰写

3GPP 技术文档提案：SA2 151#E: S2-2203755 — 23.700-80: KI#7, Sol#17: Update to enhance UE filtering policy

3GPP 技术文档提案：SA2 152#E: S2-2206122 — Solution for KI#4 & KI#7: 5GS Assistance to Federated Learning Operation (Handover in Hierarchical Federated Learning)

学术报告

2025.05.19, *EdgePrompt: A Distributed Key-Value Inference Framework for LLMs in 6G Networks*, IEEE International Conference on Computer Communications (INFOCOM)，伦敦，英国

2023.05.29, *A General Solution for Straggler Effect and Unreliable Communication in Federated Learning*, IEEE International Conference on Communications，罗马，意大利

2022.04.11, *Stochastic Resource Allocation for Outage Minimization in Random Access with Correlated Activation*, IEEE Wireless Communications and Networking Conference, 线上

2022.11.30, *Choosing a proper starting point in SGD by exploiting dependence between features — an intuition from resource allocation in event triggered communication*, Sony AI Conference, 线上

2022.05.22, *Linear Combining in Dependent α-Stable Interference*, IEEE International Conference on Communications, 线上

2019.11.29, *Choosing a proper starting point in SGD by exploiting dependence between features — an intuition from resource allocation in event triggered communication*, 索尼 AI 大会, 索尼

2019.11.13, *Copula Theory in Communication Society*, invited talk and hosted by Professor Petar POPOVSKI and Professor Troels PEDERSEN, Department of Electronics, 奥尔堡大学, 奥尔堡, 丹麦

2019.09.30, *Modeling Impulsiveness and Dependence of Interference in Wireless Communication Network*, invited talk and hosted by Professor Troels PEDERSEN and Professor Petar POPOVSKI, Department of Electronics, 奥尔堡大学, 奥尔堡, 丹麦

2019.05.30, *Interference Modeling for Wireless IoT Networks*, 特邀报告（陈立教授和 Dr. Ting-yi Wu）, 电子与通信工程学院, 中山大学, 广州, 中国

2019.03.06, *Modeling Interference with α-stable and Copulas*, ARBurst Project meeting, ITER Lab, 雷恩, 法国

2018.10.11, *Modeling of Dependence in Impulsive Interference and Copula Theory*, ARBurst Project meeting, CITI-lab, 里昂, 法国

2018.06.12, *Dependent Impulsive Interference modeling*, IRCICA Lab, 里尔, 法国

2018.02.14, *Copula Theory and Dependence in Interference*, ARBurst Project meeting, ITER Lab, 雷恩, 法国